



Universidad
Nacional
de Loja

FACULTAD DE LA ENERGÍA, LAS INDUSTRIAS Y
LOS RECURSOS NATURALES NO RENOVABLES
Carrera Computación

UNIVERSIDAD NACIONAL DE LOJA

FACULTAD LA ENERGÍA, LAS INDUSTRIAS Y LOS RECURSOS NATURALES NO RENOVABLES

CARRERA DE COMPUTACIÓN

METODOLOGÍA DE LA INVESTIGACIÓN

UNIDAD 1

ENFOQUES CUANTITATIVO, CUALITATIVO Y MIXTO

DOCENTE:

LUIS CHAMBA ERAS

ESTUDIANTE:

ROYEL IVAN JIMA PARDO

FECHA DE ENTREGA:

29/04/2026



TABLA CON LOS DIFERENTES ENFOQUES

Artículos	Enfoque Cuantitativo	Enfoque Cualitativo	Enfoque Mixto	Observación (porque ese enfoque)
[1]	X			El estudio es puramente cuantitativo, ya que se basa en la medición del rendimiento mediante métricas como exactitud, NMI, ARI y AUC en experimentos realizados sobre siete conjuntos de datos públicos [1].
[2]	X			Posee un enfoque cuantitativo centrado en la minimización del Error Cuadrático Medio (MSE) como función de pérdida para evaluar la reconstrucción de coordenadas 3D [2]. El análisis se basa en la comparación numérica directa contra el método PCA, demostrando una mejora de rendimiento de "dos veces" en términos de error [2].
[3]	X			Es un estudio cuantitativo que evalúa la eficacia de un modelo de detección de anomalías utilizando indicadores de rendimiento como F1-score (0.8398), precisión (0.8702) y recall (0.8115) [3]. El enfoque se sustenta en el análisis estadístico de señales fisiológicas y la sensibilidad de umbrales basados en percentiles [3].
[4]	X			Se clasifica como cuantitativo al centrar su evaluación en la tasa de identificación promedio (96.9%) y la Tasa de Error Igual (EER de 3.1%) [4]. La metodología emplea matrices de confusión y puntuaciones de confianza calculadas para cada

				vector de características MFCC y CENS [4].
[5]			X	Presenta un enfoque mixto. Por un lado, utiliza datos cuantitativos (error de reconstrucción de 0.009 y puntajes de juego de 17 puntos) [5]. Por otro lado, integra un análisis del nivel de satisfacción y percepción del atleta sobre la "personalización" y el "sentirse valorado", lo cual aporta un componente de evaluación cualitativa sobre la efectividad subjetiva del plan de entrenamiento [5].

Fig . 1. Tabla con diferentes enfoques de los artículos seleccionados.

Fuente: Elaboración propia con ayuda de Notebook, 2026.

REFERENCIA

- [1] Hu, Y., Yang, Z., Ouyang, S., & Liu, Y. (2025). Adversarial Masked Graph Autoencoders for Improved Graph Representation Learning. *Proceedings of the 2025 International Conference on Multimedia Retrieval, ICMR '25*, 478–486. <https://doi.org/10.1145/3731715.3733270>
- [2] Khoimov, M., Botman, S., & Natalia, S. (2024). Autoencoder-based representation learning of hand and finger movements in humans. *Proceedings of the 2023 7th International Conference on Computer Science and Artificial Intelligence, CSAI '23*, 436–441. <https://doi.org/10.1145/3638584.3638643>
- [3] Qiu, S., Chi, J., Xue, Y., & Xin, J. (2025). Based on Deep Autoencoder: An Anomaly Detection Framework for Real-Time Psychological Stress Monitoring in Underwater Confined Environments. *Proceedings of the 2025 8th International Conference on Computer Information Science and Artificial Intelligence, CISAI '25*, 411–417. <https://doi.org/10.1145/3773365.3773430>
- [4] Rajesh, S., & J, N. N. (2025). Deep Autoencoder-based Framework for Robust Singer Identification in Music Analysis. *Proceedings of the 2024 the 12th International Conference on Information Technology (ICIT), ICIT '24*, 137–144. <https://doi.org/10.1145/3718391.3718413>
- [5] Wen, N., & Diliya, D. (2024). Feature Extraction and Personalized Sports Training for Athletes Using Variational Autoencoder (VAE). *Proceedings of the 2024 International Conference on Machine Intelligence and Digital Applications, MIDA '24*, 574–580. <https://doi.org/10.1145/3662739.3672309>