

Matriz de Extracción de Artículos Científicos

Información general del estudiante (ejemplo)

- **Nombre del estudiante:**
- **Técnica de IA:** Autoencoders
- **Pregunta de investigación:** ¿Cómo contribuyen los autoencoders a la reducción de dimensionalidad?

Matriz de extracción (ejemplo con 5 artículos)

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	Y. Hu, Z. Yang, S. Ouyang, y Y. Liu, "Adversarial Masked Graph Autoencoders for Improved Graph Representation Learning," Proc. Int. Conf. Multimedia Retrieval (ICMR '25), pp. 1-9, June 2025. DOI: https://doi.org/10.1145/3731715.3733270	2025	ACM	AMGAE: Autoencoder de grafos enmascarado con aprendizaje adversarial (GAN)	Los autoencoders de grafos (GAEs) convencionales son vulnerables a perturbaciones de características y ruido.	Mejorar la robustez de los GAEs enmascarados mediante una estrategia de aprendizaje adversarial para representaciones de grafos más sólidas.	Uso de un generador (GAE enmascarado) y un discriminador (capa GNN) interconectados por una tarea de discriminación binaria (BDT) con actualizaciones alternas.	Grafos de citas y redes (Cora, CiteSeer, PubMed, Coauthor CS/Physics, etc.).	Rendimiento superior en clasificación y agrupamiento; reducción drástica de la caída de rendimiento ante ruido (1.75% vs 18.83% en modelos previos).	La ausencia de señales supervisadas en el proceso de reconstrucción base puede generar características borrosas.	Representación de grafos robusta frente a perturbaciones y ruido de datos.
2	X. Qu, D. Li, H. Zhang, H. Liu, Y. Zhao, y X. Zhang, "AutoEncoder-based Weighted Multi-modal Knowledge Graph Representation Learning," Proc. Int. Conf.	2024	ACM	AWMRL: Autoencoder ponderado para aprendizaje multimodal.	Los métodos actuales de grafos de conocimiento (KG) ignoran los errores de reconstrucción tras el mapeo de datos visuales y textuales.	Minimizar errores de reconstrucción y agregar conocimientos de diferentes modalidades (visual, textual, estructural) con pesos diferenciados.	Módulo de reconstrucción (autoencoder de 3 capas) y módulo de agregación (función de energía TransE extendida).	Grafos de conocimiento multimodales: WN9-IMG y FB-IMG.	Superó a los modelos base en predicción de enlaces y clasificación de tripletas; demostró que la estructura de autoencoder reduce el error de mapeo.	Se asume que los pesos de influencia modal son iguales para todas las entidades, lo cual no siempre ocurre en la práctica.	Mejora la calidad de los "embeddings" en grafos de conocimiento multimodales.

	Commun. Inf. Process. (ICCIP 2024), pp. 1-8, Nov. 2024. DOI: https://doi.org/10.1145/3708657.3708762										
3	S. Qiu, J. Chi, Y. Xue, y J. Xin, "Based on Deep Autoencoder: An Anomaly Detection Framework for Real-Time Psychological Stress Monitoring in Underwater Confined Environments," Proc. Int. Conf. Comput. Inf. Sci. Artif. Intell. (CISAI 2025), pp. 1-7, Sept. 2025. DOI: https://doi.org/10.1145/3773365.3773430	2025	ACM	Deep Autoencoder con normalización por lotes (Batch Normalization).	Necesidad de detectar estrés psicológico agudo (claustrofobia) en tiempo real en entornos submarinos confinados.	Identificar respuestas de estrés agudo mediante señales fisiológicas usando un marco de detección de anomalías no supervisado.	Entrenamiento no supervisado con datos normales; los errores de reconstrucción sirven como puntajes de anomalía con umbrales dinámicos.	Psicológico State Identification Dataset (HRV, GSR, EEG, temperatura cutánea, etc.).	F1-score de 0.8398; procesa lotes en 118ms, siendo apto para dispositivos vestibles (wearables).	El rendimiento puede ser sensible al tamaño de la cohorte para establecer percentiles estables.	Monitoreo de estrés no supervisado y adaptable a dispositivos de bajos recursos.
4	S. Rajesh y N. N. J, "Deep Autoencoder-based Framework for Robust Singer Identification in Music Analysis," Proc. Int. Conf. Inf. Technol. (ICIT 2024), pp. 1-8, Dec. 2024. DOI: https://doi.org/10.1145/3718391.3718413	2024	ACM	AE: Autoencoder Apilado (Stacked Autoencoder).	La identificación de cantantes en música polifónica es difícil debido al acompañamiento instrumental que enmascara a la	Proponer un sistema capaz de extraer eficazmente características vocales para una identificación precisa en entornos ruidosos.	Extracción de características MFCC y CENS procesadas a través de capas de codificación /decodificación jerárquicas del SAE.	2,000 clips musicales de 10 cantantes icónicos y contemporáneos de la India.	Tasa de identificación promedio del 96.9% en música polifónica; reducción del EER (tasa de error igual) al 3.1%.	El rendimiento se degrada significativamente cuando el acompañamiento instrumental es muy dominante sobre la voz.	Extracción robusta de características en señales de audio complejas y polifónicas.
5	N. Wen y D. Diliya, "Feature Extraction	2024	ACM	VAE: Autoencoder Variaci	Los planes de entrenamien	Aprender representaciones de característic	El codificador mapea datos a un espacio	Datos de 500 atletas (altura,	Error de reconstrucción de 0.009;	El conjunto de datos experimental es de	Personalización inteligente del

and Personalized Sports Training for Athletes Using Variational Auto Encoder (VAE)," Proc. Int. Conf. Mach. Intell. Digit. Appl. (MIDA 2024), pp. 1-7, May 2024. DOI: https://doi.org/10.1145/3662739.3672309			onal (Variational Auto-Encoder).	tradicional no considera las diferencias individuales, resultando en planes genéricos e ineficaces.	as de atletas para diseñar planes de entrenamiento personalizados y maximizar el rendimiento.	latente (media y varianza); el decodificador reconstruye datos minimizando la divergencia KL.	peso, indicadores fisiológicos) aplicados al baloncesto.	mejora en puntajes de juego (17 puntos promedio) y alta satisfacción de los atletas (90.9).	escala reducida y se centra principalmente en un deporte (baloncesto).	entrenamiento físico mediante la extracción de características latentes.
---	--	--	----------------------------------	---	---	---	--	---	--	--

REFERENCIAS

[1] Hu, Y., Yang, Z., Ouyang, S., & Liu, Y. (2025). Adversarial Masked Graph Autoencoders for Improved Graph Representation Learning. Proceedings of the 2025 International Conference on Multimedia Retrieval, ICMR <https://doi.org/10.1145/3731715.3733270>

[2] Khoimov, M., Botman, S., & Natalia, S. (2024). Autoencoder-based representation learning of hand and finger movements in humans. Proceedings of the 2023 7th International Conference on Computer Science and Artificial Intelligence, CSAI '23, 436–441. <https://doi.org/10.1145/3638584.3638643>

[3] Qiu, S., Chi, J., Xue, Y., & Xin, J. (2025). Based on Deep Autoencoder: An Anomaly Detection Framework for Real-Time Psychological Stress Monitoring in Underwater Confined Environments. Proceedings of the 2025 8th International Conference on Computer Information Science and Artificial Intelligence, CISA <https://doi.org/10.1145/3773365.3773430>

[4] Rajesh, S., & J, N. N. (2025). Deep Autoencoder-based Framework for Robust Singer Identification in Music Analysis. Proceedings of the 2024 the 12th International Conference on Information Technology (ICIT), ICIT <https://doi.org/10.1145/3718391.3718413>

[5] Wen, N., & Diliya, D. (2024). Feature Extraction and Personalized Sports Training for Athletes Using Variational Autoencoder (VAE). Proceedings of the 2024 International Conference on Machine Intelligence and Digital Applications, MIDA '24, 574–580. <https://doi.org/10.1145/3662739.3672309>